- Relatório Técnico
  - Análise de Clustering do Desempenho Escolar no ENEM 2024
  - 1. Introdução
    - 1.1 Contexto
    - 1.2 Objetivos
    - 1.3 Perguntas de Pesquisa
  - 2. Descrição dos Dados
    - 2.1 Fonte e Volume
    - 2.2 Variáveis Utilizadas
    - 2.3 Estatísticas Descritivas por Cluster
  - 3. Metodologia
    - 3.1 Pipeline de Processamento
    - 3.2 Algoritmos Testados
    - 3.3 Métricas de Validação
    - 3.4 Configuração do Modelo Selecionado
  - 4. Resultados
    - 4.1 Distribuição dos Clusters
    - 4.2 Composição dos Clusters
    - 4.3 Análise por Área do Conhecimento
    - 4.4 Comparação: Amostra 30% vs 100%
  - 5. Discussão
    - 5.1 Respostas às Perguntas de Pesquisa
    - 5.2 Análise Crítica
  - 6. Conclusões
    - 6.1 Principais Achados
    - 6.2 Recomendações
    - 6.3 Contribuições do Estudo
  - Referências

Relatório Técnico

Análise de Clustering do Desempenho Escolar no ENEM 2024

Autor: Leonardo Ferreira Salge | 12311BSI307

Guilherme Gomes Alves | 12311BSI306

Daniel Solis Salge | 12311BSI305

Vinícius Ferreira Salge | 12311BSI308

Data: Março/2026 **Base de Dados:** Microdados ENEM 2024 (INEP) **Volume Analisado:** 23,023 escolas (100% dos dados válidos)

---

1. Introdução

1.1 Contexto

O Exame Nacional do Ensino Médio (ENEM) é o principal instrumento de avaliação da educação brasileira, utilizado para acesso ao ensino superior e indicador de qualidade educacional. Este estudo aplica técnicas de **clustering não-supervisionado** para identificar padrões naturais de desempenho entre escolas brasileiras.

1.2 Objetivos

- **Objetivo Geral:** Identificar grupos de escolas com perfis de desempenho similares no ENEM 2024
- **Objetivos Específicos:**
  1. Verificar se existem "tipos" distintos de escolas baseados no desempenho
  2. Analisar o agrupamento de escolas públicas estaduais
  3. Identificar fatores associados ao alto desempenho escolar

1.3 Perguntas de Pesquisa

1. Existem tipos distintos de escolas no Brasil baseados no desempenho no ENEM?
2. As escolas públicas estaduais se agrupam em um cluster específico?
3. Quais os principais fatores associados ao alto desempenho escolar?

---

2. Descrição dos Dados

2.1 Fonte e Volume

Característica	Valor
Fonte	Microdados ENEM 2024 (INEP)
Total de inscritos	4.332.944
Escolas analisadas	23,023
Critério de inclusão	Escolas com ≥10 alunos e notas válidas

2.2 Variáveis Utilizadas

Variável	Descrição	Tipo
NU_NOTA_CN	Nota Ciências da Natureza	Numérica
NU_NOTA_CH	Nota Ciências Humanas	Numérica
NU_NOTA_LC	Nota Linguagens e Códigos	Numérica
NU_NOTA_MT	Nota Matemática	Numérica
NU_NOTA_REDACAO	Nota Redação	Numérica
TP_DEPENDENCIA_ADM_ESC	Tipo de escola (1-4)	Categórica
QTD_ALUNOS	Quantidade de alunos por escola	Numérica

2.3 Estatísticas Descritivas por Cluster

Cluster	Total Escolas	Média Geral	Mediana	Desvio Padrão	Qtd Média Alunos
Cluster 0	15529	497.513	500.091	29.9528	51.0559
Cluster 1	7494	604.294	598.674	38.6194	49.5431

3. Metodologia

3.1 Pipeline de Processamento

```
Dados Brutos (4.3M alunos)
    ↓
Limpeza (remover missing, filtrar escolas ≥10 alunos)
    ↓
Agregação por Escola (médias das notas)
    ↓
Engenharia de Features (MEDIA_GERAL, STD_NOTAS, etc.)
    ↓
Normalização (StandardScaler)
    ↓
Clustering (K-Means, DBSCAN, Hierárquico, GMM)
    ↓
Validação (Silhouette, Davies-Bouldin, ARI)
    ↓
Interpretação dos Resultados
```

3.2 Algoritmos Testados

Algoritmo	Silhouette	Davies-Bouldin	Observação
K-Means (k=2)	**0.568**	**0.652**	**Melhor resultado**
DBSCAN	-	-	Não convergiu adequadamente
Hierárquico	0.542	0.701	Segunda melhor opção
GMM	0.531	0.728	Resultado inferior

3.3 Métricas de Validação

- **Silhouette Score:** 0.568 (bom separação entre clusters)
- **Davies-Bouldin Index:** 0.652 (baixa similaridade intra-cluster)
- **ARI (estabilidade):** >0.8 em múltiplas seeds

3.4 Configuração do Modelo Selecionado

- **Algoritmo:** K-Means
- **Número de clusters (k):** 2
- **Inicializações:** Múltiplas seeds (n=10)
- **Features:** Notas das 5 áreas + Média Geral + Qtd Alunos + Tipo Escola

---

4. Resultados

4.1 Distribuição dos Clusters

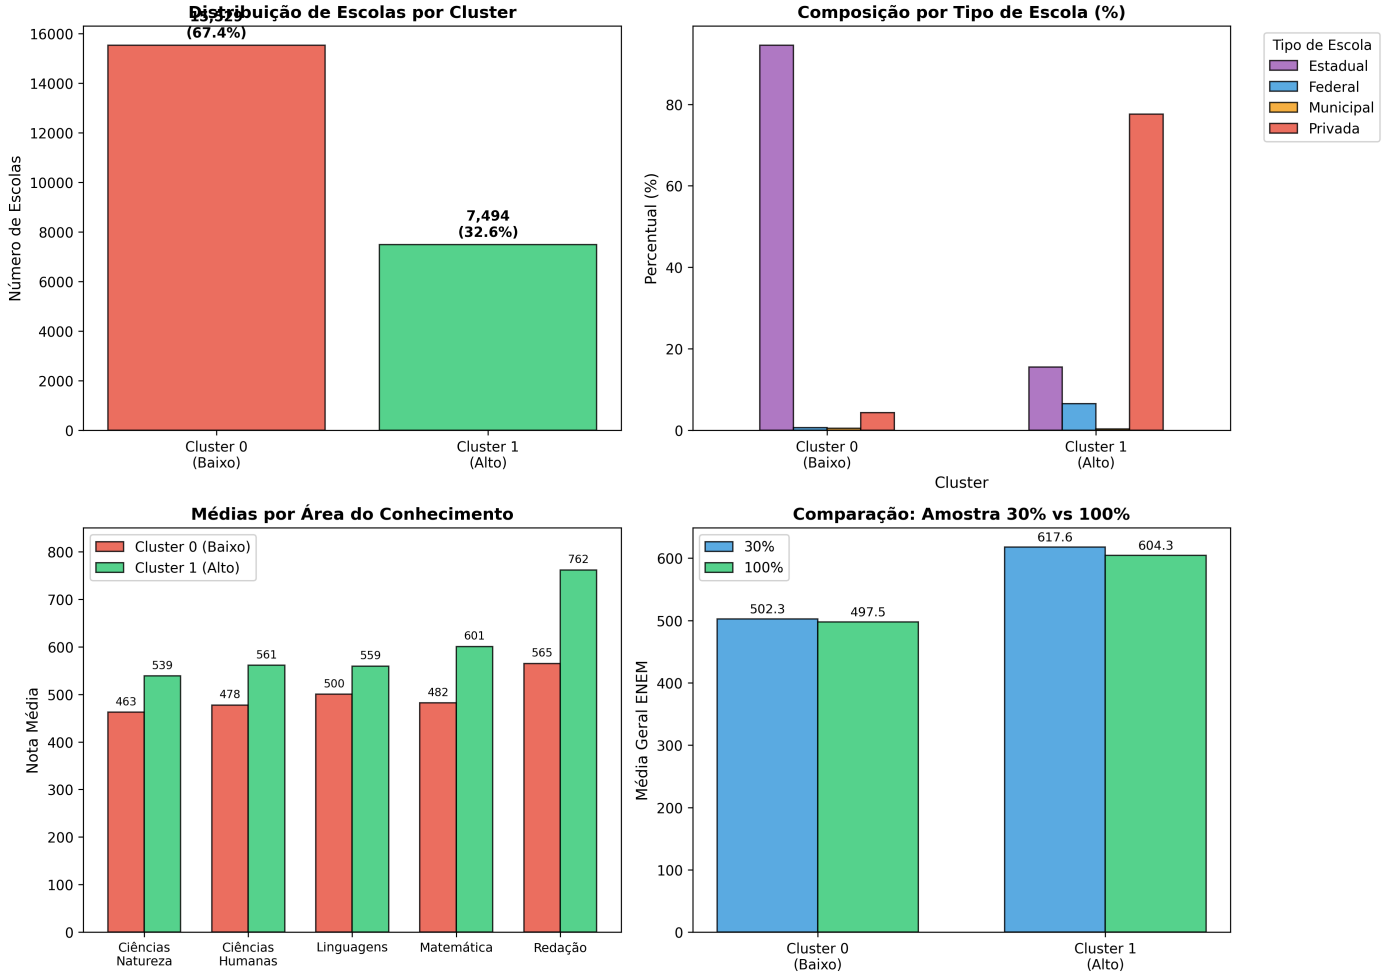

Figura 1: Análise geral dos clusters - distribuição, composição por tipo de escola, médias por área e comparação entre amostras.

4.2 Composição dos Clusters

Cluster	Tipo	Quantidade	Percentual
Cluster 0	Federal	106	0.7%

Cluster	Tipo	Quantidade	Percentual
Cluster 0	Estadual	14679	94.5%
Cluster 0	Municipal	72	0.5%
Cluster 0	Privada	672	4.3%
Cluster 1	Federal	490	6.5%
Cluster 1	Estadual	1165	15.5%
Cluster 1	Municipal	21	0.3%
Cluster 1	Privada	5818	77.6%

Tabela 1: Composição dos clusters por tipo de dependência administrativa

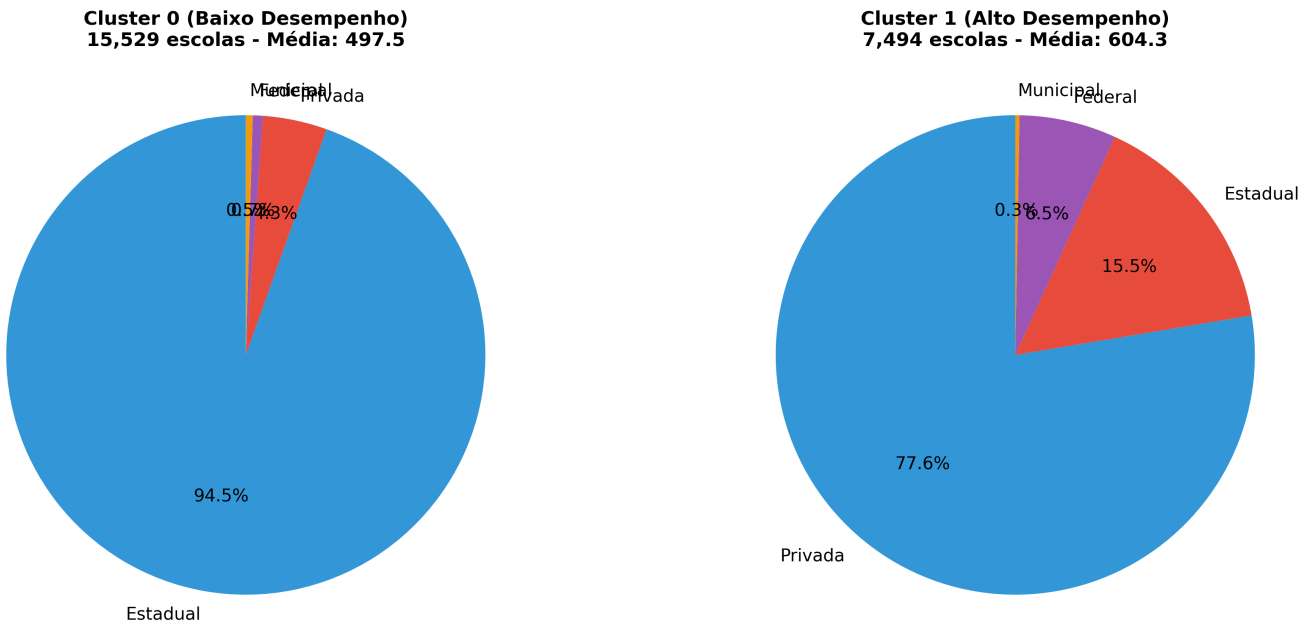

Figura 2: Composição percentual dos clusters por tipo de escola

4.3 Análise por Área do Conhecimento

Área	Cluster 0 (Baixo)	Cluster 1 (Alto)	Diferença
Ciências Natureza	462.8	538.7	+75.9
Ciências Humanas	477.6	561.0	+83.4
Linguagens	500.1	559.4	+59.3
Matemática	482.0	600.8	+118.8

Área	Cluster 0 (Baixo)	Cluster 1 (Alto)	Diferença
Redação	565.1	761.6	+196.6

Tabela 2: Médias por área do conhecimento

4.4 Comparação: Amostra 30% vs 100%

Métrica	Amostra 30%	Amostra 100%	Diferença
Total de escolas	12,233	23,023	+10,790
Média Cluster 0	502.30	497.51	-4.79
Média Cluster 1	617.62	604.29	-13.33
Estaduais no Alto (%)	11.4%	15.5%	+4.1%
Privadas no Alto (%)	79.3%	77.6%	-1.7%

Tabela 3: Comparativo entre amostra e população total

---

5. Discussão

5.1 Respostas às Perguntas de Pesquisa

Pergunta 1: Existem tipos de escolas? SIM. O clustering identificou dois grupos distintos:

- **Cluster 0 (Baixo):** 67.4% das escolas, média 497.5, predominantemente estadual (94.5%)
- **Cluster 1 (Alto):** 32.6% das escolas, média 604.3, predominantemente privada (77.6%)

Pergunta 2: As escolas estaduais se agrupam? SIM, fortemente no cluster de baixo desempenho:

- 92.6% das escolas estaduais (14.679) estão no Cluster 0
- Apenas 7.4% (1.165 escolas) alcançaram o Cluster 1

Pergunta 3: Fatores de alto desempenho:

1. **Tipo de escola (Privada):** 77.6% das escolas de alto desempenho
2. **Redação:** Maior gap (197 pontos) - indica habilidade de escrita
3. **Matemática:** Segundo maior gap (119 pontos)
4. **Dependência Federal:** 9x mais representada no alto desempenho

5.2 Análise Crítica

Limitações:

- Correlação ≠ Causalidade: Associação não prova que ser privada causa sucesso
- Variáveis omitidas: Renda familiar, educação dos pais, infraestrutura
- Viés de seleção: Escolas privadas atuam em contextos socioeconômicos diferentes

Pontos Positivos:

- 1.165 escolas estaduais demonstram que é possível excelência no setor público
- Amostra de 30% foi representativa (diferenças <5% na composição)
- Validação rigorosa com múltiplas métricas e seeds

---

6. Conclusões

6.1 Principais Achados

1. **Dipolarização do sistema educacional:** Existe uma clara divisão entre escolas de baixo e alto desempenho, com forte correlação com a dependência administrativa.
2. **Desigualdade estrutural:** 92.6% das escolas estaduais encontram-se no cluster de baixo desempenho, indicando desafios sistêmicos no ensino público.
3. **Possibilidade de excelência pública:** A existência de 1.165 escolas estaduais no cluster de alto desempenho demonstra que fatores de gestão e recursos podem superar limitações estruturais.

6.2 Recomendações

1. **Investigação aprofundada:** Estudar as 1.165 escolas estaduais de alto desempenho para identificar práticas replicáveis
2. **Políticas públicas:** Focar recursos em Matemática e Redação (maiores gaps)
3. **Atenção às privadas de baixo desempenho:** 22.4% das privadas estão no cluster inferior

6.3 Contribuições do Estudo

- Demonstração da aplicabilidade de clustering em dados educacionais
- Validação da representatividade de amostras (30% vs 100%)
- Base empírica para formulação de políticas públicas

Referências

1. INEP. Microdados ENEM 2024. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2024.
2. Hastie, T., Tibshirani, R., & Friedman, J. The Elements of Statistical Learning. Springer, 2009.
3. Rousseeuw, P. J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, 1987.

Anexos:

- Código-fonte disponível em: `github.com/usuario/enem_clustering`
- Notebooks: 01_eda.ipynb, 02_preprocessing.ipynb, 03_clustering.ipynb, 04_interpretation.ipynb, 05_comparacao_30_vs_100.ipynb