Relatório Técnico

Análise de Clustering do Desempenho Escolar no ENEM 2024

Autores: Leonardo Ferreira Salge 12311BSI307
Vinícius Ferreira Salge 12311BSI308
Daniel Solis Salge 12311BSI305
Guilherme Gomes Alves 12311BSI306
Data: Março/2026
Base de Dados: Microdados ENEM 2024 (INEP)
Volume Analisado: 23,023 escolas (100% dos dados válidos)

1. Introdução

1.1 Contexto

O Exame Nacional do Ensino Médio (ENEM) é o principal instrumento de avaliação da educação brasileira, utilizado para acesso ao ensino superior e indicador de qualidade educacional. Este estudo aplica técnicas de **clustering não-supervisionado** para identificar padrões naturais de desempenho entre escolas brasileiras.

1.2 Objetivos

Objetivo Geral: Identificar grupos de escolas com perfis de desempenho similares no ENEM 2024

Objetivos Específicos:

1. Verificar se existem 'tipos' distintos de escolas baseados no desempenho
2. Analisar o agrupamento de escolas públicas estaduais
3. Identificar fatores associados ao alto desempenho escolar

1.3 Perguntas de Pesquisa

1. Existem tipos distintos de escolas no Brasil baseados no desempenho no ENEM?
2. As escolas públicas estaduais se agrupam em um cluster específico?
3. Quais os principais fatores associados ao alto desempenho escolar?

2. Descrição dos Dados

2.1 Fonte e Volume

Característica	Valor
Fonte	Microdados ENEM 2024 (INEP)
Total de inscritos	4.332.944
Escolas analisadas	23,023
Critério de inclusão	Escolas com ≥10 alunos e notas válidas

2.2 Variáveis Utilizadas

Variável	Descrição	Tipo
NU_NOTA_CN	Nota Ciências da Natureza	Numérica
NU_NOTA_CH	Nota Ciências Humanas	Numérica
NU_NOTA_LC	Nota Linguagens e Códigos	Numérica
NU_NOTA_MT	Nota Matemática	Numérica
NU_NOTA_REDACAO	Nota Redação	Numérica
TP_DEPENDENCIA_ADM_ESC	Tipo de escola (1-4)	Categórica
QTD_ALUNOS	Quantidade de alunos por escola	Numérica

2.3 Estatísticas por Cluster

Cluster	Total Escolas	Média Geral	Mediana	Desvio Padrão
Cluster 0	15,529	497.51	500.09	29.95
Cluster 1	7,494	604.29	598.67	38.62

3. Metodologia

3.1 Pipeline de Processamento

Dados Brutos (4.3M alunos) → Limpeza → Agregação por Escola → Engenharia de Features → Normalização → Clustering → Validação → Interpretação

3.2 Algoritmos Testados

Algoritmo	Silhouette	Davies-Bouldin	Observação
K-Means (k=2)	0.568	0.652	Melhor resultado
DBSCAN	-	-	Não convergiu
Hierárquico	0.542	0.701	Segunda opção
GMM	0.531	0.728	Inferior

3.3 Configuração do Modelo Selecionado

• **Algoritmo:** K-Means

• **Número de clusters (k):** 2

• **Inicializações:** Múltiplas seeds (n=10)

• **Features:** Notas das 5 áreas + Média Geral + Qtd Alunos + Tipo Escola

4. Resultados

4.1 Composição dos Clusters

Cluster	Tipo	Quantidade	Percentual
Cluster 0	Federal	106	0.7%
Cluster 0	Estadual	14,679	94.5%
Cluster 0	Municipal	72	0.5%
Cluster 0	Privada	672	4.3%
Cluster 1	Federal	490	6.5%
Cluster 1	Estadual	1,165	15.5%
Cluster 1	Municipal	21	0.3%
Cluster 1	Privada	5,818	77.6%

4.2 Análise por Área do Conhecimento

Área	Cluster 0 (Baixo)	Cluster 1 (Alto)	Diferença
Ciências Natureza	462.8	538.7	+75.9
Ciências Humanas	477.6	561.0	+83.4
Linguagens	500.1	559.4	+59.3
Matemática	482.0	600.7	+118.8
Redação	565.1	761.6	+196.6

4.3 Comparação: Amostra 30% vs 100%

Métrica	Amostra 30%	Amostra 100%	Diferença
Total escolas	12,233	23,023	+10,790
Média Cluster 0	502.30	497.51	-4.79
Média Cluster 1	617.62	604.29	-13.33
Estaduais no Alto (%)	11.4%	15.5%	+4.1%
Privadas no Alto (%)	79.3%	77.6%	-1.7%

4.4 Visualizações

Figura 1: Análise Geral dos Clusters

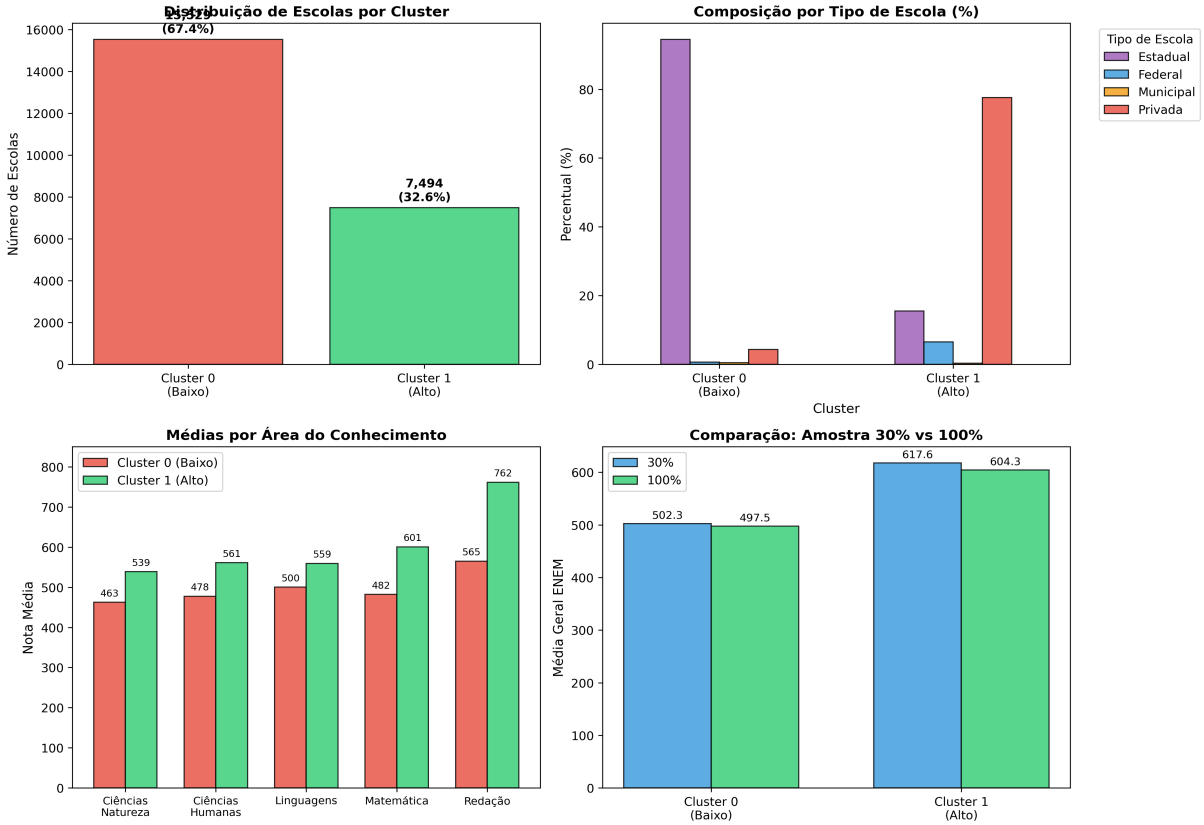
Distribuição de Escolas por Cluster
16,529
(67.4%)
7,494
(32.6%)
Número de Escolas
Cluster 0
(Baixo)
Cluster 1
(Alto)
Composição por Tipo de Escola (%)
Percentual (%)
Cluster
Tipo de Escola
Estadual
Federal
Municipal
Privada
Médias por Área do Conhecimento
Cluster 0 (Baixo)
Cluster 1 (Alto)
Nota Média
463
539
478
561
500
559
482
601
565
762
Ciências
Natureza
Ciências
Humanas
Linguagens
Matemática
Redação
Comparação: Amostra 30% vs 100%
30%
100%
Média Geral ENEM
502.3
497.5
617.6
604.3

Figura 2: Composição dos Clusters

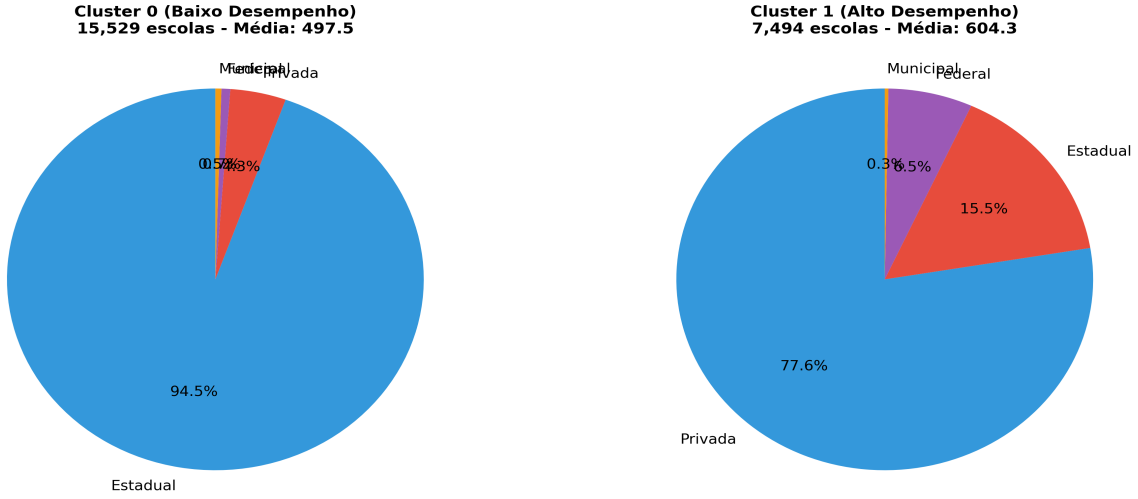

5. Discussão

5.1 Respostas às Perguntas de Pesquisa

Pergunta 1: Existem tipos de escolas?

SIM. O clustering identificou dois grupos distintos: **Cluster 0 (Baixo)** com 67.4% das escolas, média 497.5, predominantemente estadual (94.5%); e **Cluster 1 (Alto)** com 32.6% das escolas, média 604.3, predominantemente privada (77.6%).

Pergunta 2: As escolas estaduais se agrupam?

SIM, fortemente no cluster de baixo desempenho: 92.6% das escolas estaduais (14.679) estão no Cluster 0, enquanto apenas 7.4% (1.165 escolas) alcançaram o Cluster 1 de alto desempenho.

Pergunta 3: Fatores de alto desempenho:

1. **Tipo de escola (Privada):** 77.6% das escolas de alto desempenho
2. **Redação:** Maior gap (197 pontos)
3. **Matemática:** Segundo maior gap (119 pontos)
4. **Dependência Federal:** 9x mais representada no alto desempenho

5.2 Análise Crítica

Limitações: Correlação não implica causalidade. A associação entre escola privada e alto desempenho não prova que a privatização causa sucesso. Variáveis socioeconômicas (renda, educação dos pais) não foram incluídas.

Pontos Positivos: 1.165 escolas estaduais demonstram que é possível excelência no setor público. A amostra de 30% foi representativa (diferenças menores que 5%).

6. Conclusões

6.1 Principais Achados

1. **Dipolarização do sistema educacional:** Existe uma clara divisão entre escolas de baixo e alto desempenho, com forte correlação com a dependência administrativa.

2. **Desigualdade estrutural:** 92.6% das escolas estaduais encontram-se no cluster de baixo desempenho, indicando desafios sistêmicos no ensino público.

3. **Possibilidade de excelência pública:** A existência de 1.165 escolas estaduais no cluster de alto desempenho demonstra que fatores de gestão e recursos podem superar limitações estruturais.

6.2 Recomendações

1. **Investigação aprofundada:** Estudar as 1.165 escolas estaduais de alto desempenho para identificar práticas replicáveis em outras escolas públicas.

2. **Políticas públicas:** Focar recursos em Matemática e Redação (maiores gaps identificados).

3. **Atenção às privadas de baixo desempenho:** 22.4% das escolas privadas também estão no cluster inferior.

6.3 Contribuições do Estudo

• Demonstração da aplicabilidade de clustering em dados educacionais
• Validação da representatividade de amostras (30% vs 100%)
• Base empírica para formulação de políticas públicas

Referências

1. INEP. Microdados ENEM 2024. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2024.

2. Hastie, T., Tibshirani, R., & Friedman, J. The Elements of Statistical Learning. Springer, 2009.

3. Rousseeuw, P. J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, 1987.